@page { size: A4; margin: 17mm 16mm 18mm; } * { box-sizing: border-box; } body { font-family: 'STHeiti', 'Arial Unicode MS', sans-serif; font-size: 9pt; line-height: 1.48; color: #202936; } h1,h2,h3,h4 { color: #183b5b; page-break-after: avoid; } h1 { font-size: 22pt; border-bottom: 1px solid #b9c8d7; padding-bottom: 5mm; } h2 { font-size: 16pt; margin-top: 8mm; } h3 { font-size: 12pt; margin-top: 6mm; } p { margin: 2.5mm 0; orphans: 3; widows: 3; } a { color: #1767a5; overflow-wrap: anywhere; } code { font-family: 'Menlo', 'STHeiti', monospace; font-size: 8pt; background: #f1f4f7; padding: 0.4mm 1mm; border-radius: 2px; white-space: pre-wrap; } pre { background: #f3f5f7; border: 1px solid #d5dde5; padding: 3mm; white-space: pre-wrap; overflow-wrap: anywhere; page-break-inside: avoid; } pre code { padding: 0; background: transparent; } blockquote { border-left: 3px solid #9ab3ca; margin: 3mm 0; padding: 1mm 4mm; color: #465566; } table { width: 100%; border-collapse: collapse; margin: 4mm 0; font-size: 8pt; page-break-inside: auto; } thead { display: table-header-group; } tr { page-break-inside: avoid; } th, td { border: 1px solid #788b9d; padding: 1.5mm 2mm; vertical-align: top; overflow-wrap: anywhere; } th { background: #e7eef5; color: #183b5b; font-weight: bold; } ul, ol { padding-left: 6mm; margin: 2mm 0; } li { margin: 1mm 0; } hr { border: 0; border-top: 1px solid #c9d3dc; margin: 6mm 0; } img { max-width: 100%; }

Codex 對話紀錄：AIoT-HW2-MultipleLR

- 工作區：/Users/jay/Projects/AIoT-HW2-MultipleLR
- 對話：分析外送市場資料集
- 匯出範圍：本對話中可見的使用者與 Codex 訊息；不包含內部推理、原始工具輸出或系統指示。
- 共 27 個含文字訊息的對話回合。

2026-11-01 05:32:43 UTC

使用者

我在做研究所 AIoT 課程作業 HW2：Multiple Linear Regression。要求：

- 從 Kaggle 選一個特徵數 14–39 個的資料集，做多元線性回歸
- 依 CRISP-DM 六階段完成分析
- 必須做特徵選擇與模型評估
- 結果要有預測圖，加上信賴區間或預測區間
- 繳交 GitHub repo 與網頁（GitHub Pages）
- 加分：網頁用下拉選單切換兩種題目；可輸入任意 CSV 網址

我選的資料集是 Kaggle「Global Food Delivery Restaurant Market 2026」：
https://www.kaggle.com/datasets/luthfimuthathohirin/global-food-delivery-restaurant-market-2026 CSV 路徑
/Users/jay/Projects/AIoT-HW2-MultipleLR/global_food_delivery_enriched_market_2026.csv 已附上。

請先做資料理解：

1. 筆數、欄位數、每個欄位的型別與缺值數
2. 用中文說明每個欄位的意義
3. 哪些欄位不是特徵（ID、文字說明等）
4. 判斷這是真實資料還是合成資料，理由是什麼

進度

我會先檢視 CSV 的結構與欄位內容，再核對 Kaggle 頁面的資料集說明，據此整理欄位意義並判斷資料來源性質。

Codex

資料概況

CSV 共 8,000 筆、26 個欄位，所有欄位都沒有缺值。欄位型別以檔案讀取結果為準：數字欄位是 float64 或 int64，類別與文字欄位是 object，is_peak_hour 是 bool。

欄位	型別	缺值	中文意義
order_id	object	0	訂單識別碼
metro_city	object	0	都會城市
cuisine_category	object	0	餐點或料理類別
order_channel	object	0	訂購管道，如外送平台、自取
order_value_usd	float64	0	訂單原始金額（美元）
discount_applied_usd	float64	0	折扣金額（美元）
delivery_distance_km	float64	0	外送距離（公里）
estimated_prep_time_min	int64	0	預估備餐時間（分鐘）
actual_delivery_time_min	float64	0	外送路程時間（分鐘）
delivery_fee_usd	float64	0	外送費（美元）
customer_rating	float64	0	顧客評分
restaurant_price_tier	object	0	餐廳價位級距
is_peak_hour	bool	0	是否為尖峰時段
weather_condition	object	0	天氣狀況
net_effective_order_price	float64	0	折扣後加上外送費的有效訂單金額
discount_percentage	float64	0	折扣占原始訂單金額的百分比
delivery_speed_km_per_hr	float64	0	推算的外送速度（公里／小時）
total_fulfillment_time_min	float64	0	從備餐到完成交付的總履約時間
delivery_fee_ratio	float64	0	外送費占訂單金額的比例
customer_spending_tier	object	0	顧客消費級距
logistics_friction_index	float64	0	物流摩擦程度指標
estimated_restaurant_net_margin_usd	float64	0	估算的餐廳淨利潤（美元）
customer_satisfaction_tier	object	0	顧客滿意度級距
primary_satisfaction_driver	object	0	主要滿意度影響因素
cot_market_dynamics_rationale	object	0	以印尼文撰寫的市場情境解釋文字
confidence_score	float64	0	資料中的信心分數

哪些欄位不是一般模型特徵

- 識別欄位： order_id 是唯一識別碼，不應直接當數值特徵。
- 自由文字說明： cot_market_dynamics_rationale 是每筆各不相同的長文字，主要是敘述性內容；若未做 NLP，不適合直接用於一般多元線性回歸。
- 可能造成目標洩漏或冗餘的衍生欄位： net_effective_order_price、discount_percentage、delivery_speed_km_per_hr、total_fulfillment_time_min、delivery_fee_ratio、logistics_friction_index、estimated_restaurant_net_margin_usd、customer_spending_tier、customer_satisfaction_tier、primary_satisfaction_driver、confidence_score。是否排除要看預測目標和這些欄位的產生方式；若它們是用目標值或事後資訊計算而來，納入模型會高估效果。
- 類別欄位：
  城市、料理、管道、價位級距、尖峰時段、天氣等可以作為特徵，但需先編碼；它們不是可直接投入模型的連續數值。

資料是真實還是合成？

較合理的判斷是：這份檔案很可能是合成或經過生成式加工的資料，不能當成已驗證的真實營運紀錄。 這是根據 CSV 本身的跡象推斷，而非 Kaggle 頁面可讀的明確來源聲明：其中包含逐筆生成、格式高度一致的印尼文敘述；每列都有接近 1 的信心分數；並包含多個由原始欄位計算或分類出的指標。部分欄位關係也值得查核，例如自取訂單的距離與外送時間為 0，而速度欄位看起來是由距離與時間推算而來。

Kaggle 頁面目前無法讀取到可用的資料字典或生成方式說明，因此無法只憑頁面確認其來源。作業報告建議寫成「依欄位模式判斷為疑似合成資料；尚未找到可核實的真實交易來源」，並避免把模擬出的關聯解讀成真實市場因果關係。(Kaggle 資料集頁面)

2026-11-01 05:35:12 UTC

使用者

請幫我決定預測目標：

1. 列出可以當連續目標的候選欄位，各自用線性回歸快速試一次（8:2 切分、seed 42、類別欄 one-hot），比較測試集 R^2
2. 檢查是否有特徵是由目標用公式算出來的，或是結果發生後才會知道的（資料洩漏），逐一說明理由。請把「資料洩漏」和「由其他特徵算出來的冗餘欄位」分開列
3. 檢查不同 order_channel 的目標分布有沒有異常
4. 檢查保留的數值特徵之間有沒有完全或近乎完全的線性關係，並計算 VIF
5. 建議最適合的目標與要保留的特徵，特徵數要在 14–39 之間

進度

我會逐一測試連續數值欄位作為目標，並在建模比較時先排除明顯的識別、文字、目標衍生及事後欄位，避免分數被洩漏抬高。接著檢查通路分布、特徵線性依賴與 VIF，再給出符合特徵數要求的建議方案。

Codex

1. 連續目標欄位快速比較

我用固定的 80:20 切分與 seed 42 比較數值欄位。類別欄位做 one-hot 編碼。初步模型使用訂單基本資訊（城市、料理、通路、訂單金額、折扣、距離、預估備餐時間、外送費、餐廳價位、尖峰時段、天氣），並從特徵中移除當次目標欄位。

候選目標	測試集 R^2	解讀
delivery_fee_usd	0.969	高，但與外送距離高度相關；費用規則可能直接使用距離
delivery_distance_km	0.935	高，但主要可由外送費推估，兩者關係近乎線性
actual_delivery_time_min	0.923	高，但只適用於外送訂單；其他通路的值全是 0
order_value_usd	0.570	中等，作為目標較容易避免結構性零值與直接公式洩漏
discount_percentage	0.572	需留意它由折扣金額和訂單金額計算
delivery_speed_km_per_hr	0.759	由距離與時間推得，存在直接公式關係
total_fulfillment_time_min	0.945	可能由備餐時間與外送時間加總
estimated_restaurant_net_margin_usd	0.991	與訂單金額高度相關，可能是公式估算結果
logistics_friction_index	0.988	很可能由距離、時間等物流欄位計算
net_effective_order_price	1.000	使用訂單金額、折扣與外送費即可精確推得，屬明顯公式洩漏
delivery_fee_ratio	0.543	比例型衍生欄位；定義可能使用訂單金額或外送費
discount_applied_usd	0.158	低，現有欄位對折扣金額的解釋力有限
estimated_prep_time_min	0.180	低，其他可用欄位無法有效預測
customer_rating	0.141	低，其他可用欄位解釋力有限
confidence_score	0.108	低；且分數集中在約 0.99，實務意義不清楚

這是快速基準，不是特徵選擇後的最終模型。特別是表中幾個 R^2
很高的目標，通常伴隨公式關係或資料生成規則，不能直接視為有泛化能力的成果。

2. 資料洩漏與冗餘欄位

以下依「預測目標為 order_value_usd，希望在訂單完成前預測」來分類。

資料洩漏或事後資訊

- order_id：唯一識別碼，沒有合理的泛化資訊；不要作為模型特徵。
- cot_market_dynamics_rationale：文字敘述包含訂單金額、折扣、外送費、時間、利潤及滿意度等結果摘要，相當於把答案寫回特徵。
- customer_rating、customer_satisfaction_tier、primary_satisfaction_driver：通常要在服務或訂單完成後才能知道，不適用於下單前預測訂單金額。
- actual_delivery_time_min、delivery_speed_km_per_hr、total_fulfillment_time_min：履約或運送完成後才知道；若目標是在下單時預測，屬時點洩漏。
- estimated_restaurant_net_margin_usd：明確以估算利潤呈現，且與訂單金額相關性高，可能由金額或其他結果資訊推算。
- customer_spending_tier：消費級距很可能由訂單金額或累積消費金額分箱得出；若用來預測訂單金額，會洩漏目標資訊。
- confidence_score：來源和計算方式不明，值集中在高分區間。若它是資料生成或事後評分結果，不應作為預測特徵。

由其他欄位計算出的冗餘欄位

- net_effective_order_price：從樣本定義看，等於 order_value_usd - discount_applied_usd + delivery_fee_usd。若預測它，使用這三項會直接得到答案。
- discount_percentage：由折扣金額和訂單金額計算；若目標是訂單金額，可能形成目標的比例洩漏。
- delivery_speed_km_per_hr：由距離和外送時間推得，與兩者冗餘。
- total_fulfillment_time_min：看起來由備餐時間與實際外送時間加總；需檢查是否每列都符合加總關係。
- delivery_fee_ratio：比例欄位，可能由外送費及訂單金額計算；公式需依資料定義確認。
- logistics_friction_index：很可能由距離、時間、通路等欄位組成的衍生指標。
- estimated_restaurant_net_margin_usd：可能由訂單金額及成本假設估算，與 order_value_usd 高度相關（相關係數約 0.983）。它不是獨立的原始測量。

discount_applied_usd 與 order_value_usd 的相關係數約 0.486。折扣金額不一定是目標的直接公式，但它可能在訂單成立時才確定。若要做嚴格的「下單前預測」，應排除；若做下單時預測，且折扣已知，則可保留。

3. 不同通路的目標分布

actual_delivery_time_min 的通路分布有明顯結構性差異：

訂單通路	筆數	平均實際外送時間	中位數	範圍
Dine-In POS	1,577	0	0	0–0
Online Delivery App	5,255	17.16 分鐘	11.6	8–75
Takeaway / Pickup	1,168	0	0	0–0

因此，若把所有通路一起預測外送時間，模型很容易靠辨識通路來分辨零值與非零值；高 R^2 部分反映通路規則，而非一般化的時間預測能力。若選這個目標，應只分析外送平台訂單，並在報告中明確界定範圍。

其他目標的通路均值也不同，但沒有同樣明確的零值分群。例如 order_value_usd 的各通路平均約為 30.29、29.92、31.49 美元，分布較接近。

4. 數值特徵線性關係與 VIF

先就訂單金額模型的可用連續特徵檢查：訂單金額、折扣金額、外送距離、預估備餐時間、外送費。為避免把目標本身放入 VIF 計算，以下 VIF 使用其餘四個預測變數（order_value_usd 是目標，不納入 VIF）。

數值特徵	VIF
discount_applied_usd	1.31
delivery_distance_km	5.77

數值特徵	VIF
estimated_prep_time_min	1.10
delivery_fee_usd	5.98

沒有發現完全線性依賴；距離與外送費的相關係數約 0.904，VIF 約
5.8–6.0，表示兩者共線性偏高，係數可能不穩定。其他這幾個特徵的 VIF 低。

另外，數值欄位全體檢查中，net_effective_order_price 與 order_value_usd 相關約
0.976，estimated_restaurant_net_margin_usd 與 order_value_usd 相關約
0.983，支持它們是高度依賴訂單金額的衍生欄位。檢查完整欄位時，應先排除目標及衍生欄位，再計算模型特徵的 VIF。

5. 建議方案

我建議選 order_value_usd
作為目標。它避免外送時間的通路零值問題，也沒有像有效訂單金額或外送速度那樣明顯的目標公式；目前基準 R^2 約
0.570，適合作為特徵選擇與模型評估的起點。

建議保留的 14 個原始特徵欄位：

1. metro_city
2. cuisine_category
3. order_channel
4. discount_applied_usd
5. delivery_distance_km
6. estimated_prep_time_min
7. delivery_fee_usd
8. restaurant_price_tier
9. is_peak_hour
10. weather_condition
11. actual_delivery_time_min
12. customer_rating
13. estimated_restaurant_net_margin_usd
14. confidence_score

這樣符合 14–39 個原始特徵欄位的數量限制，但其中
actual_delivery_time_min、customer_rating、estimated_restaurant_net_margin_usd 和 confidence_score
的可用時點或計算方式有疑慮。若作業要做嚴謹的下單前預測，應將它們排除；此時可用的乾淨候選特徵不足 14
個，建議回頭確認作業的「特徵數」是按原始欄位數還是 one-hot
後欄位數計算。別為了湊足欄位數納入事後資料或疑似由目標推算的欄位。

重要限制： 本輪測試是快速比較，不是最終特徵選擇；表中衍生目標的 R^2 僅能作為診斷，不能當成有效模型成績。

2026-11-01 05:36:42 UTC

使用者

你在第 3 點已經指出，只分析外送訂單就能解決零值問題。 而 order_value_usd 方案扣掉有疑慮的欄位後只剩 10
個特徵，不符合作業要求。

請改以 actual_delivery_time_min 為目標，只保留 Online Delivery App 訂單，重新評估：

1. 哪些欄位是由外送時間算出來的，或送達後才知道（資料洩漏）
2. net_effective_order_price、discount_percentage、delivery_fee_ratio、customer_spending_tier、estimated_restaurant_net_margin_usd 都是由下單當下的資訊算出來的，在預測外送時間時算洩漏嗎？

3. 排除洩漏後還剩幾個特徵？其中有沒有完全共線的組合（例如 net_effective_order_price 是否等於 order_value_usd − discount_applied_usd + delivery_fee_usd）？請計算 VIF
4. 列出最終的特徵清單與測試集 R^2

進度

同意，將資料限制在 Online Delivery App 後，外送時間的零值問題就不再主導模型。我會按「下單時可知」作為時間界線重新篩欄位，核對衍生公式，再在外送子集上重算特徵數、共線性、VIF 與 R^2。

Codex

我把「預測時點」定為訂單成立時，並只保留 Online Delivery App 訂單（5,255 筆）。因此下單時已知的訂單價格與其衍生欄位不會因為它們是公式欄位就自動算作洩漏；關鍵是它們是否使用了目標或送達後才知道的資訊。

1. 外送時間衍生或送達後才知道的欄位

以下欄位不應用於預測 actual_delivery_time_min：

- actual_delivery_time_min：目標欄位本身。
- delivery_speed_km_per_hr：由距離與實際外送時間推算；資料中與該公式吻合至小數精度。
- total_fulfillment_time_min：每筆都等於 estimated_prep_time_min + actual_delivery_time_min，直接含有目標。
- customer_rating、customer_satisfaction_tier、primary_satisfaction_driver：服務完成後才會知道。
- cot_market_dynamics_rationale：敘述中重述了實際外送時間等結果資訊。
- logistics_friction_index：欄位定義不明，可能含實際物流時間；為避免洩漏，建議排除。
- confidence_score：計算時點與依據不明，無法確認下單時可用，建議排除。
- order_id：識別碼，不作為預測特徵。

estimated_prep_time_min 是預估備餐時間，和已完成的實際外送時間不同；在下單時確實可取得的前提下，可以保留。

2. 指定的下單資訊衍生欄位算不算洩漏？

以「下單時預測外送時間」為準，這些欄位不因為是衍生欄位就構成目標洩漏，前提是它們只使用當下已知的訂單資訊：

- net_effective_order_price：資料中每筆都符合 order_value_usd − discount_applied_usd + delivery_fee_usd。
- discount_percentage：符合 discount_applied_usd ÷ order_value_usd × 100，差異僅在四捨五入。
- delivery_fee_ratio：符合 delivery_fee_usd ÷ order_value_usd，差異僅在四捨五入。
- customer_spending_tier：若它只是依本筆訂單金額分級，下單時可知；若實際上是用未來或累積消費資料建立，則應排除。
- estimated_restaurant_net_margin_usd：未能從可見欄位確認精確公式。它與 order_value_usd 幾乎完全線性相關，但下單資訊衍生出的冗餘欄位不等於目標洩漏。考量公式來源不明且會加劇共線性，最終模型先排除。

已驗證的冗餘公式包括
net_effective_order_price；它雖不含目標外送時間，仍與金額、折扣、外送費完全共線，應從迴歸特徵中移除。

3. 排除洩漏與共線特徵後的數量、VIF

排除目標、識別碼、敘述文字、送達後欄位，以及直接由目標計算的欄位後，留下 16 個下單時可用的欄位。再移除：

- net_effective_order_price：可由訂單金額、折扣、外送費精確算出。
- estimated_restaurant_net_margin_usd：計算方式不明，且與訂單金額幾乎完全線性相關。

最終保留 14 個原始特徵欄位，符合數量要求。數值特徵 VIF 如下：

數值特徵	VIF
order_value_usd	2.22
discount_applied_usd	2.97

數值特徵	VIF
delivery_distance_km	7.02
estimated_prep_time_min	1.10
delivery_fee_usd	7.39
discount_percentage	2.26
delivery_fee_ratio	1.81

保留的特徵中沒有完全共線的組合。距離與外送費相關係數約 0.919，VIF 約
7，表示兩者共線性偏高；我先保留兩者，因為距離和外送費可能各自有助於預測配送時間，報告中應提醒係數解讀可能不穩。移除 net_effective_order_price 後，數值特徵設計矩陣不再完全秩不足。

4. 最終特徵與測試集 R^2

最終特徵清單：

1. metro_city
2. cuisine_category
3. order_channel
4. order_value_usd
5. discount_applied_usd
6. delivery_distance_km
7. estimated_prep_time_min
8. delivery_fee_usd
9. restaurant_price_tier
10. is_peak_hour
11. weather_condition
12. discount_percentage
13. delivery_fee_ratio
14. customer_spending_tier

在 5,255 筆外送訂單上，以 seed 42 做 80:20 切分、類別欄位 one-hot 編碼，線性回歸的測試集 $R^2 = 0.8783$（測試集 1,051 筆）。這是按上述 14 個原始欄位計算的基準結果；其中 order_channel
在此子集內固定為單一類別，沒有額外預測資訊。discount_percentage、delivery_fee_ratio
與金額欄位有公式關係，雖不洩漏外送時間，仍可能帶來冗餘。

2026-11-01 05:37:48 UTC

使用者

order_channel 在外送訂單子集裡只有一個類別，one-hot 後會完全消失，不應算進特徵數，實際上只有 13 個。

estimated_restaurant_net_margin_usd 雖然和 order_value_usd
高度共線，但不是由外送時間算出來的，也不是送達後才知道的。我想把它保留為候選特徵，讓後面的特徵選擇與 VIF
去處理，報告裡也可以討論這件事。

請刪除 order_channel、加回 estimated_restaurant_net_margin_usd，重新列出最終 14 個特徵，並重算 VIF 與測試集 R^2。

進度

我會按你指定的欄位集合重跑同一個外送訂單子集與 seed 42 切分：移除無變異的 order_channel，加入估算淨利，並用最終 14 個特徵重新計算 VIF 和測試集 R^2。

Codex

已移除在外送訂單子集中沒有變異的 order_channel，並把 estimated_restaurant_net_margin_usd 加回候選特徵。以下使用相同設定重算：5,255 筆外送訂單、80:20 切分、seed 42、類別欄位 one-hot。

最終 14 個特徵

1. metro_city
2. cuisine_category
3. order_value_usd
4. discount_applied_usd
5. delivery_distance_km
6. estimated_prep_time_min
7. delivery_fee_usd
8. restaurant_price_tier
9. is_peak_hour
10. weather_condition
11. discount_percentage
12. delivery_fee_ratio
13. customer_spending_tier
14. estimated_restaurant_net_margin_usd

數值特徵 VIF

數值特徵	VIF
order_value_usd	11,379,379
discount_applied_usd	2.97
delivery_distance_km	7.02
estimated_prep_time_min	1.10
delivery_fee_usd	7.39
discount_percentage	2.26
delivery_fee_ratio	1.82
estimated_restaurant_net_margin_usd	11,379,862

estimated_restaurant_net_margin_usd 與 order_value_usd 的相關係數約 0.99999996。用訂單金額單獨線性擬合淨利，斜率約 0.370、截距約 −1.500，最大殘差約 0.0052 美元。這顯示兩者幾乎完全共線；保留淨利作為候選特徵是合理的，但後續特徵選擇很可能需要在兩者中取捨。距離與外送費的 VIF 也偏高，約為 7.02 與 7.39。

測試集 R^2

R^2 = 0.8781，測試集 1,051 筆。

此分數和上一版相同，因為移除的 order_channel 在子集中為常數，one-hot 後本來就不產生有效欄；加入的淨利欄位與訂單金額幾乎完全線性相關，因此對這次最小平方解的預測幾乎沒有影響。VIF 則清楚呈現這種共線性，值得在特徵選擇與報告中說明。

2026-11-01 05:41:39 UTC

使用者

依照上面的結論，在專案中新增：

1. data/prepare_food_delivery.py：讀取 /Users/jay/Projects/AIoT-HW2-MultipleLR/global_food_delivery_enriched_market_2026.csv，只保留 Online Delivery App 訂單，保留最終 14 個特徵與目標 actual_delivery_time_min，is_peak_hour 轉成 0/1，目標放最後一欄，輸出 data/food_delivery_2026.csv，並印出原始與輸出的筆數、欄位數、缺值數。每個被刪除的欄位都要註解原因（非特徵、資料洩漏、完全共線、常數欄）
2. .gitignore：排除 data/raw/、.DS_Store、pycache/

進度

我先檢查專案現有檔案與 .gitignore，再新增整理腳本和輸出資料。腳本會把每個排除欄位及其原因列在註解中，並按指定路徑寫出 CSV 與摘要統計。

Codex

已新增 prepare_food_delivery.py 與 .gitignore。

腳本篩選 Online Delivery App 訂單，保留指定的 14 個特徵與目標欄位，將 is_peak_hour 轉為 0/1，並把目標放在最後一欄。每個排除欄位的原因都已寫在腳本註解中。

已執行腳本，輸出 food_delivery_2026.csv：

- 原始資料：8,000 筆、26 欄、0 個缺值
- 輸出資料：5,255 筆、15 欄（14 個特徵 + 1 個目標）、0 個缺值

.gitignore 已排除 data/raw/、.DS_Store 與 __pycache__/。

2026-11-01 05:42:57 UTC

使用者

原始 CSV 目前放在專案根目錄，但 .gitignore 只排除 data/raw/，推上 GitHub 時會把 8 MB 的原始檔一起推上去。 請把 global_food_delivery_enriched_market_2026.csv 移到 data/raw/，同步修改腳本的 SOURCE_CSV 路徑，並重新執行，確認輸出不變。

進度

我會把原始 CSV 移到 data/raw/，更新腳本來源路徑後重新產生整理檔，再比對移動前後整理資料是否完全一致。

Codex

已將原始 CSV 移至 data/raw/，並更新 prepare_food_delivery.py 的來源路徑。重新執行後仍輸出 5,255 筆、15 欄、0 個缺值；與移動前的輸出檔逐位元比對完全一致。原始檔已不在專案根目錄，且會被 .gitignore 排除。

2026-11-01 05:44:10 UTC

使用者

針對處理後的 data/food_delivery_2026.csv 補充資料理解：目標的分布（平均、中位數、範圍、偏態，以及剛好等於最小值的比例）、數值特徵與目標的相關係數、天氣與尖峰時段對目標的影響、共線性問題。

接著寫 CRISP-DM 的「商業理解」：要解決什麼問題、給誰用、有什麼限制、具體的成功標準。

最後把商業理解、資料理解、資料準備整理成 docs/crisp-dm-notes.md。資料準備要包含前面幾輪的發現：洩漏欄位與理由、完全共線的 net_effective_order_price、常數欄 order_channel、淨利與訂單金額的近乎線性關係與 VIF。之後的階段會繼續補充。

進度

我會從整理後的 CSV 計算目標分布、數值特徵相關、天氣與尖峰時段的分組差異，以及最終特徵的 VIF，並把這些結果連同前幾輪的資料洩漏判斷整理進 docs/crisp-dm-notes.md。

Codex

已建立 crisp-dm-notes.md，整理了商業理解、資料理解與資料準備，後續階段可接續補充。

資料理解包含目標分布、數值特徵與目標的相關係數、天氣與尖峰時段分組摘要，以及共線性與 VIF。資料準備部分記錄了最終 14 個候選特徵、洩漏欄位及排除理由、net_effective_order_price 的完全線性關係、常數 order_channel，以及淨利與訂單金額的近乎完全線性關係。

分析結果是根據目前的 data/food_delivery_2026.csv 計算；天氣與尖峰時段部分是描述性比較，文件中也註明不能解讀為因果效果。

2026-11-01 05:46:00 UTC

使用者

crisp-dm-notes.md 請修改兩處：

1. 資料理解的「資料來源與範圍」補上 Kaggle 連結：
   https://www.kaggle.com/datasets/luthfimuthathohirin/global-food-delivery-restaurant-market-2026
2. 成功標準第 1 點的 $R^2 \geqslant 0.878$
   是從測試集算出來的，再拿來當測試集的門檻有循環論證的問題，而且對使用者沒有直接意義。請改成用業務語言訂的標準：

- 測試集 RMSE $\leqslant$ 5 分鐘（顧客可接受的預估誤差）
- 95% 預測區間的實際涵蓋率落在 93–97%（給顧客的時間範圍要可信）
- 特徵選擇後的模型用更少特徵，測試集 R^2 比全特徵模型下降不超過 0.01 0.878
  改列為「全特徵參考基準」，不作為門檻。其餘成功標準保留。

進度

我會直接修改這兩段，保留其餘成功標準，並把 0.878 移到參考基準說明，不再作為測試門檻。

Codex

已更新 crisp-dm-notes.md：

- 在「資料來源與範圍」加入 Kaggle 資料集連結。
- 將成功標準改為 RMSE $\leqslant$ 5 分鐘、95% 預測區間實際涵蓋率 93–97%，以及特徵選擇後使用較少特徵且測試集 R^2 比全特徵模型下降不超過 0.01。
- 將 $R^2 = 0.878$ 移為全特徵參考基準，並註明不作為成功門檻。

其餘成功標準維持不變。

2026-11-01 05:53:39 UTC

使用者

下拉選單的第二題，我選了 Kaggle「Life Expectancy (WHO)」：
https://www.kaggle.com/datasets/kumarajarshi/life-expectancy-who 檔案在 data/raw/Life Expectancy Data.csv。

請做資料理解：

1. 筆數、欄位數、每個欄位的型別與缺值數，用中文說明欄位意義
2. 欄位名稱有沒有格式問題（例如前後空白）
3. 資料結構是什麼（每一列代表什麼），這對訓練/測試切分有什麼影響
4. 有沒有明顯不合理的數值（例如超出合理範圍的死亡數、人口數、BMI）

進度

我會檢查本機 CSV 的欄位、型別、缺值、名稱格式與數值範圍，並核對 Kaggle 資料集說明以理解每列的觀察單位及切分上的注意事項。

Codex

1. 資料規模、欄位型別與缺值

本機檔案 data/raw/Life Expectancy Data.csv 有 2,938 筆、22 欄。每列是某國某年的觀察資料，共 193 個國家、2000–2015 年。以下缺值數以 CSV 讀取後的空值計算。

欄位	型別	缺值	中文意義
Country	object	0	國家
Year	int64	0	年份
Status	object	0	國家發展分類：Developed 或 Developing
Life expectancy	float64	10	預期壽命（年）
Adult Mortality	float64	10	成人死亡指標；資料字典通常定義為 15–60 歲死亡機率（每千人）
infant deaths	int64	0	嬰兒死亡數量
Alcohol	float64	194	人均酒精消費量
percentage expenditure	float64	0	人均健康支出相對於人均 GDP 的百分比指標
Hepatitis B	float64	553	B 型肝炎疫苗覆蓋率（%）
Measles	int64	0	麻疹病例數
BMI	float64	34	平均 BMI
under-five deaths	int64	0	五歲以下兒童死亡數量
Polio	float64	19	小兒麻痺疫苗覆蓋率（%）
Total expenditure	float64	226	政府衛生支出占政府總支出的比例（%）
Diphtheria	float64	19	白喉疫苗覆蓋率（%）
HIV/AIDS	float64	0	HIV/AIDS 對 0–4 歲死亡率的指標（每千名活產嬰兒）
GDP	float64	448	人均 GDP（美元）
Population	float64	652	人口數
thinness 1-19 years	float64	34	10–19 歲人口消瘦率指標（欄名寫作 1–19）
thinness 5-9 years	float64	34	5–9 歲人口消瘦率指標
Income composition of resources	float64	167	人類發展指數中收入構面的資源組成指標
Schooling	float64	163	平均受教育年數

欄位定義依 Kaggle 資料集所列名稱與常見資料字典解讀；Kaggle 頁面目前沒有提供可讀取的欄位說明文字，建議提交前再和資料集說明或原始引用核對。Kaggle：Life Expectancy (WHO)

2. 欄位名稱格式

有多個欄位名稱帶有前置或尾端空白，部分還有連續空白：

- 尾端空白：Life expectancy 、Measles 、under-five deaths 、Diphtheria
- 前置空白：BMI、 HIV/AIDS、 thinness 1-19 years、 thinness 5-9 years
- 內部連續空白： thinness 1-19 years

這會讓程式讀取欄位時容易漏掉空白而出錯。建議準備資料時先對欄名執行 .str.strip()，再將連續空白正規化；保留原欄名與標準化對照，避免欄位來源混淆。

3. 每列代表什麼，對切分有什麼影響

每列代表一個國家 – 年份觀察值，不是獨立抽樣的個人。資料有 193 個國家、16 年期間；每國最多 16 列，但部分國家年份不完整。檢查未發現重複的 Country–Year 組合或完全重複列。

同一國家的相鄰年份通常高度相關，隨機按列切分可能把同一國家的不同年份分到訓練集與測試集，讓測試結果偏樂觀。切分方式應配合預測用途：

- 若目標是預測未來年份，建議按年份做時間切分，例如較早年份訓練、較晚年份測試。
- 若目標是推廣至模型未見過的國家，建議按 Country 分組切分，確保測試國家不出現在訓練集。
- 若只是估計對已涵蓋國家與年份的隨機留出表現，才考慮列級隨機切分，並在報告中說明同國家跨集合的限制。

4. 明顯不合理或需查核的數值

以下是資料品質警訊，不代表每個極端值都必然錯誤；死亡病例等欄位也可能是國家總數，不能在未確認單位前直接當作比率。

- 人口數有明顯異常。 Population 最小值為 34，低於 100,000 的有 412 筆。不少較大國家出現數千或數萬人口，且同一國相鄰年份常跳動 10 倍以上。例如阿富汗 2014 年為 327,582、2015 年為 33,736,494；印度的人口則達約 12.9 億。這很像不同紀錄的單位或位數不一致，建模前應核對原始來源。
- BMI 有大量低值。 BMI 範圍為 1.0–87.3，低於 10 的有 283 筆，例如越南 2002 年為 1.0。若欄位意指國家平均 BMI，這些值很可疑，可能是錯置、漏位或單位問題。
- 死亡數與麻疹病例最大值很大，但可能是總數。 嬰兒死亡最大值為 1,800、五歲以下死亡最大值為 2,500、麻疹病例最大值為 212,183。這些若是國家年度總數，數量級可能合理；若資料字典把它們描述成每千人比率，則與數值型態不一致，需要核對欄位定義。
- 成人死亡指標有高值。 範圍為 1–723，超過 500 的有 54 筆；最高值集中於辛巴威 2003–2005 年。極端但未必不可能，建議保留並檢查影響力。
- 疫苗覆蓋率欄位範圍合理。 Hepatitis B、Polio、Diphtheria 都落在 0–100 之間。
- 收入組成指標範圍合理。 Income composition of resources 在 0–0.948；Schooling 在 0–20.7 年。但零值也可能代表缺失或未估計，需查看原始定義後再決定處理方式。
- 缺值集中在重要特徵。 Hepatitis B 缺 553 筆、Population 缺 652 筆、GDP 缺 448 筆。缺值處理方法應只在訓練集估計，避免切分資訊洩漏。

2026-11-01 05:55:32 UTC

使用者

第 4 點還漏了兩個問題，請檢查：

1. BMI：你只提到低於 10 的值。請看中位數，以及超過 40、超過 50 的筆數，並比較美國、日本、印度的 BMI 中位數。國家平均 BMI 合理範圍大約是多少？這欄還能用嗎？
2. percentage expenditure：你解讀為健康支出占 GDP 的百分比，但請檢查超過 100 的筆數和等於 0 的筆數，這和百分比的定義一致嗎？

另外請統計 Income composition of resources 和 Schooling 等於 0 的筆數，判斷是否是用 0 代替缺值。

進度

我會針對 BMI、percentage expenditure、Income composition of resources 和 Schooling 直接計數，並查看美國、日本、印度的 BMI 中位數；再依欄位定義判斷零值與極端值是否像缺值或指標尺度問題。

Codex

BMI

BMI 有 2,904 個非缺值，中位數 43.5，範圍 1.0–87.3。

檢查	筆數
BMI > 40	1,528
BMI > 50	1,139
BMI < 10	283

美國、日本、印度的國家年度 BMI 中位數如下：

國家	年數	中位數	範圍
美國	16	65.4	6.1–69.6
日本	16	25.65	22.2–29.0
印度	16	14.65	11.4–18.7

如果這欄代表國家平均 BMI，中位數 43.5，以及美國中位數 65.4 都很難視為合理的平均值；低至 1.0 的值也可疑。作為粗略檢核，國家成人平均 BMI 通常會落在約 18–35 的範圍，這不是硬性生理界線，但足以顯示這份資料的 BMI 欄有嚴重異常。

因此不建議未經查證就把原始 BMI 當成一般連續特徵使用。建議先核對 Kaggle 資料的來源欄位與單位；若無法解釋這些數值，可在建模時排除 BMI，或做含與不含 BMI 的敏感度比較。

percentage expenditure

該欄有 611 筆等於 0，另有 1,303 筆大於 100，最大值 19,479.91。如果它真的是「衛生支出占 GDP 的百分比」，如此大量超過 100 的值和該解讀不一致。WHO 的健康支出占 GDP 指標確實以 GDP 百分比表示，因此超過 100 值應先查核定義、尺度或資料品質。WHO 指標定義

該欄常見說明寫作健康支出占 GDP 的百分比，但本檔數值看起來不像可直接解讀的百分比。零值可能代表未提供資料或以 0 代替缺失，也可能是實際數值經處理後為 0；僅靠 CSV 無法確定。建議先查原始資料字典，釐清公式及單位，再決定轉換或排除。

0 值是否像缺失值

欄位	原始缺值	等於 0	初步判斷
Income composition of resources	167	130	很可能有部分 0 是缺值或未估計的代碼。該指標範圍為 0–1，理論上 0 不必然無效，但多國連續多年為 0 的模式值得核對。
Schooling	163	28	0 年受教育可能在定義上成立，但部分國家多年連續為 0，對國家平均受教育年數而言很可疑，可能是缺值代碼。

不能只因為數值為 0 就一律改成缺值；應核對資料字典，並檢查 0 值的國家與年份分布。若確認是缺失代碼，應在資料準備階段轉成缺值，且後續填補值只能由訓練集估計。

2026-11-01 05:57:05 UTC

使用者

Kaggle 頁面沒有可用的資料字典，無法再查證，請直接根據資料做決定。目標是 Life expectancy，請幫我決定資料準備方式：

1. Country 要不要當特徵？
2. BMI、percentage expenditure、Population 這三欄要保留、轉換還是刪除？
3. Income composition of resources 和 Schooling 的 0 值要不要轉成缺值？
4. 缺值處理：直接刪除缺值列 vs 補值，各剩幾筆、涵蓋幾個國家、各有什麼風險。缺值特別多的欄位（例如 Hepatitis B）要不要整欄刪除？
5. 計算 VIF，找出完全或近乎完全共線的特徵；也說明哪些特徵和目標在定義上有關係
6. 隨機切分、依國家分組切分、依年份切分，這份作業建議用哪一種？

7. 建議最終的特徵清單，特徵數要在 14–39 之間

Codex

建議採用的準備方案

以 Life expectancy 為目標，建議把每列視為「國家 – 年份」觀察值，並以國家分組切分評估模型能否推廣到未見過的國家。下方的特徵數按原始欄位計，不按 one-hot 展開後的欄數計。

1. Country：不納入特徵

Country 有 193 個類別。若 one-hot 編碼，會增加約 192 欄，超出作業希望控制的特徵規模，也容易讓模型記住特定國家的固定差異。

我的建議是先排除 Country，保留 Status、Year 及各項健康、經濟指標。這樣模型評估可集中在跨國可共用的變數關係。相應地，測試集應按國家分組，避免同一國家不同年份同時出現在訓練集與測試集。

2. BMI、percentage expenditure、Population

- BMI：刪除。 中位數 43.5，美國、日本、印度的國家年度中位數分別為 65.4、25.65、14.65；283 筆低於 10、1,528 筆高於 40。對國家平均 BMI 而言，這種範圍與跨國差異很可疑，直接保留可能讓模型學到資料錯誤。
- percentage expenditure：保留並做 log1p 轉換。 它有 611 筆為 0、1,303 筆大於 100，最大值約 19,480，不能直接當作一般百分比解讀。因為它仍可能含有健康支出的相對資訊，建議先以 log(1 + x) 降低極端右偏的影響，並在報告中註明單位不明、解讀有限。0 值先保留，不擅自判成缺值。
- Population：刪除。 有 652 筆缺值；另有 412 筆小於 100,000，且部分國家相鄰年份出現數十倍或百倍跳動。這些跡象顯示人口欄有嚴重尺度或記錄品質問題，單純取對數不能修正錯值。

3. 收入組成與教育年數的 0 值

- Income composition of resources：130 筆等於 0，另有 167 筆原始缺值。
- Schooling：28 筆等於 0，另有 163 筆原始缺值。

兩欄的 0 值都集中在部分國家及早期年份，像是連續多年整段為 0；對國家收入組成指標及平均受教育年數而言，這更像未估計值或缺值代碼。建議將 0 轉成缺值，再用訓練集的中位數補值；另加缺值指示欄可保留「原先缺資料」這項資訊。填補值與指示欄的建立都只能依訓練集決定。

4. 刪除缺值列還是補值？

以下筆數以目標非缺值為前提。特徵數依建議最終清單計算，且已排除 BMI、Population、Country。

方法	可用筆數	涵蓋國家	主要取捨
任一候選特徵缺值就刪除（完整案例）	1,853	147	流程簡單，但會刪掉約 37% 的目標有效資料，且不同國家、年份可能不均勻
中位數補數值缺值、眾數補類別缺值	2,928	183	保留較多資料；補值可能壓低變異，需加缺值指示欄並只用訓練集估計

建議採補值方案。 僅因 Hepatitis B 有 553 個缺值就刪整欄並非必要：保留它並補值時，可以使用 2,928 筆、183 國；若要求它完整而刪列，完整案例只剩 1,853 筆、147 國。若後續比較發現它對模型沒有穩定貢獻，再由特徵選擇決定是否移除。

對照來看，即使完全不要求 Hepatitis B 完整，其他欄位完整案例也只有 2,301 筆、155 國；這顯示逐列刪除仍會損失不少資料。

5. 共線性與和目標有關的特徵

以建議數值欄位進行診斷：對偏態計數與金額使用 log1p，將收入組成及 Schooling 的 0 轉缺值，再以各欄中位數補值。以下 VIF 是未含 Country/Status one-hot 欄位的初步診斷；正式建模應只用訓練集重算。

數值特徵	VIF
under-five deaths	170.36
infant deaths	161.88

數值特徵	VIF
thinness 1-19 years	8.76
thinness 5-9 years	8.73
Income composition of resources	7.13
Schooling	5.65
其餘數值欄位	約 1.18–2.44

infant deaths 與 under-five deaths 的相關係數約 0.997，VIF 極高，後續模型應考慮只留一項，或由特徵選擇決定。兩個 thinness 欄位相關係數約 0.939，也有明顯共線性；收入組成與 Schooling 的 VIF 也偏高。

與目標的關係方面：

- Adult Mortality 與預期壽命在概念上直接相關：較高的成人死亡指標通常意味較低的預期壽命。相關係數約 -0.696。它不是由目標直接算出的欄位，但若目標是預測未來，必須確保這項資料在預測時點已可取得。
- infant deaths、under-five deaths 、 HIV/AIDS 都是死亡相關指標，和生命表及預期壽命有直接概念關聯；其中嬰幼兒死亡率也可能是壽命估計的重要輸入或代理變數。若同年目標與特徵來自相同估計流程，可能帶來高度目標資訊重疊。應把這些視為高風險候選變數，在報告中說明，並比較含／不含它們的模型。
- Schooling、收入、疫苗覆蓋等變數與壽命有合理的健康與社會經濟關聯，但不是目標的直接公式欄位。
- 年份、經濟指標和健康指標都可能與壽命趨勢相關；這不代表因果關係。

6. 建議的切分方式

三種方式中，建議用
依國家分組切分。此資料每國有多個年份，列級隨機切分會把同一國家的相似紀錄放進訓練及測試集，容易高估表現。以固定 seed 42 隨機抽 20% 國家作測試，約為 39 國、594 筆；其中目標有效約 592 筆，其餘國家資料約 2,344 筆作訓練。

依年份切分適合評估未來年份，但若測試年份的健康與經濟特徵仍是同年觀測，這測的是「已取得該年指標後估計壽命」的 nowcast，不是真正年初預測未來。真正的未來預測需把特徵改為前一年或更早的值。國家分組切分則較適合目前這份特徵表與跨國泛化目標。

7. 建議最終特徵清單

共 18 個原始特徵，在作業要求的 14–39 個範圍內：

1. Year
2. Status
3. Adult Mortality
4. infant deaths
5. Alcohol
6. percentage expenditure（log1p）
7. Hepatitis B
8. Measles （log1p）
9. under-five deaths （log1p）
10. Polio
11. Total expenditure
12. Diphtheria
13. HIV/AIDS
14. GDP（log1p）
15. thinness 1-19 years
16. thinness 5-9 years
17. Income composition of resources（0 轉缺值）

18. Schooling（0 轉缺值）

目標是 Life expectancy 。Country、BMI、Population 不納入。最終特徵選擇應只在訓練集進行，並特別檢視高 VIF 的死亡數及 thinness 欄位。

2026-11-01 05:59:24 UTC

使用者

你的方案有兩點和我們的網頁不相容，請調整：

1. 補值必須只用訓練集估計，但網頁是在瀏覽器裡切分資料，前處理腳本拿不到切分結果；在腳本裡補值等於用了測試集的資訊。所以改用完整案例：0 值轉成缺值後，刪除任何候選特徵有缺值的列。請重算筆數與國家數。
2. 我同意依國家分組切分，之後會修改網頁支援。輸出的 CSV 請保留 Country 欄作為分組依據（不當特徵），放在第一欄。

另外，infant deaths 沒做 log1p，但同性質的 under-five deaths 有做，請統一處理。做過 log1p 的欄位請改名加上 log1p_ 前綴，讓網頁上看得出來。

調整後，新增 data/prepare_life_expectancy.py：讀取 data/raw/Life Expectancy Data.csv，清理欄位名稱（去除前後空白、合併連續空白），依結論處理，輸出 data/life_expectancy.csv（Country 第一欄、目標 Life expectancy 最後一欄），並印出原始與輸出的筆數、欄位數、國家數、缺值數。每個處理步驟都要註解原因。

進度

我會依照網頁的切分方式限制，改成前處理階段不做任何補值：先把 Income composition of resources 和 Schooling 的 0 改成缺值，再對目標及候選特徵做完整案例刪除。輸出會保留 Country 作分組欄，但不列入 18 個模型特徵；所有 log1p 欄位都會加上前綴。

Codex

已新增並執行 prepare_life_expectancy.py。

輸出檔 life_expectancy.csv 保留 Country 作為第一欄的分組依據（不當模型特徵）、18 個候選特徵，並將 Life expectancy 放在最後一欄。infant deaths 與 under-five deaths 都做了 log1p 轉換，和其他轉換欄位一樣加上 log1p_ 前綴。欄名清理、排除 BMI 與 Population、將指定 0 值轉為缺值、完整案例刪列等步驟都已在腳本中註明原因。

執行結果：

- 原始資料：2,938 筆、22 欄、193 個國家、2,563 個缺值
- 輸出資料：1,789 筆、20 欄、147 個國家、0 個缺值
- 輸出包含 1 個 Country 分組欄、18 個特徵和 1 個目標欄。

2026-11-01 06:00:30 UTC

使用者

在 docs/crisp-dm-notes.md 新增「第二題：平均壽命預測」章節，格式和第一題一致，包含：

1. 商業理解：問題、使用者、限制、成功標準。成功標準請用業務語言訂定（例如誤差幾年可以接受、預測區間涵蓋率），不要用測試集算出的數字當門檻
2. 資料理解：前面發現的欄名空白、國家－年份結構、缺值、BMI／percentage expenditure／Population 的異常、0 值代替缺值、共線性與 VIF、和目標在定義上相關的死亡率欄位
3. 資料準備：每個處理步驟與理由、為什麼用完整案例而不是補值、為什麼依國家分組切分、最終 18 個特徵

另外在文件開頭加一段簡短的「兩題比較」：資料來源（合成 vs 真實）、主要挑戰（資料洩漏 vs 資料品質與缺值）、切分方式（隨機 vs 依國家分組）。

進度

我會沿用文件中第一題的 CRISP-DM 格式，在開頭加入兩題比較，再新增第二題的商業理解、資料理解與資料準備。成功標準會用可解釋的年數誤差與預測區間涵蓋率，不引用測試集結果當門檻。

Codex

已在 crisp-dm-notes.md 開頭新增兩題比較，並加入「第二題：平均壽命預測」的商業理解、資料理解與資料準備。

第二題成功標準採業務語言設定：MAE ⩽ 3 年、名義 95% 預測區間的實際涵蓋率為
90–98%，並要求特徵選擇後以較少特徵達成相近表現。文件也整理了資料品質、缺值與 0
值處理、BMI／支出／人口欄位判斷、共線性與高目標關聯死亡率欄位，以及完整案例與依國家分組切分的理由。

文件記載的準備結果為 1,789 筆、147 個國家、18 個候選特徵；`Country` 保留作分組欄，目標 `Life expectancy` 放在最後。

2026-11-01 06:03:29 UTC

使用者

接下來改網頁。這是一個純前端的多元線性回歸網頁（index.html、app.js、regression.js、config.js），請先閱讀這幾個檔案了解架構。

需求一：題目改成下拉選單（作業加分項要求「下拉視窗」）

1. config.js 的 presets 改成兩題，移除原本的 50 Startups 與 Boston Housing：

- 外送時間預測：data/food_delivery_2026.csv，target 為 actual_delivery_time_min，來源 Kaggle Global Food Delivery Restaurant Market 2026（附連結）
- 平均壽命預測：data/life_expectancy.csv，target 為 Life expectancy，來源 Kaggle Life Expectancy (WHO)（附連結）
  預設載入外送時間預測。

2. index.html 目前的題目是膠囊按鈕（radiogroup），改成 ，選項為兩題加上「自訂 CSV 網址」。選自訂時保留原本可輸入任意 CSV 網址的功能（作業的另一個加分項）。
3. 注意資料是相對路徑：網址輸入框是 type="url"，不接受相對路徑；判斷目前網址屬於哪一題的比對邏輯也要能處理相對路徑。
4. 頁尾的資料來源要顯示 Kaggle 連結。

改完說明改了哪些地方。

進度

我先讀 `index.html`、`app.js`、`regression.js` 和 `config.js`，確認題目選擇、CSV
載入及頁尾來源目前怎麼串接，再按現有架構改成下拉選單。

Codex

已將題目切換改為下拉選單，預設選「外送時間預測」，並把預設題目改成兩份新資料集及其 Kaggle 來源連結。

- config.js：設定兩題的相對 CSV 路徑、目標欄位與 Kaggle 來源。
- index.html：題目選擇改為 `<select>`，包含兩題與「自訂 CSV 網址」；自訂網址欄仍可輸入任意絕對 CSV 網址。
- app.js：將相對預設路徑解析成頁面上的絕對 URL，並以正規化後的網址比對題目；頁尾連到對應 Kaggle 頁面。切換到平均壽命資料時，也會排除 `Country`，避免把分組欄當模型特徵。
- regression.js：支援由題目設定排除非特徵欄位。
- style.css：新增下拉選單樣式。

我依序閱讀了設定、頁面結構、載入與狀態處理、CSV
特徵建構等程式。這次沒有修改切分邏輯；平均壽命資料的依國家分組切分仍待後續網頁支援。

2026-11-01 06:05:53 UTC

使用者

需求二：平均壽命題要依國家分組切分

1. config.js 的 preset 新增 groupColumn 設定（平均壽命題設為 Country）。groupColumn 自動視為排除欄位，不當特徵、也不能被選為 target；excludedColumns 保留給其他非特徵欄使用。自訂 CSV 不設定 groupColumn，維持隨機切分。
2. 分組切分：用同一個 seed 打亂國家，測試集取 ceil(國家數 × 測試比例) 個國家，這些國家的所有列都進測試集，其餘進訓練集。
3. 網頁上的切分說明要顯示切分方式，例如「依 Country 分組：訓練 117 國／測試 30 國」。
4. 其他用到訓練/測試切分的地方（模型、殘差表、預測器滑桿範圍）都要沿用同一個切分結果。
5. 注意：缺值列被略過後，分組要用保留下來的列對應的國家，不要和原始列的索引錯位。

改完說明改了哪些地方。

進度

我會追蹤目前 buildDataset 回傳的有效列索引、切分結果如何傳到模型與預測器，以及切分說明的呈現位置。分組標籤會從缺值過濾後保留下來的列取得，再以同一組 train/test 索引供各功能共用。

進度

分組流程已接到資料準備、目標選單和模型切分：Country
會自動排除於特徵與目標之外，分組標籤是從缺值過濾後的有效列建立。接著我檢查 JavaScript 語法與切分說明所用的欄位。

Codex

已完成依國家分組切分。

- config.js：平均壽命題新增 groupColumn: 'Country'。分組欄會自動排除於特徵與目標選單；excludedColumns 仍用於其他非特徵欄。自訂 CSV 沒有 groupColumn 時維持隨機切分。
- regression.js：新增分組切分，先排序國家，再用指定 seed 打亂，依 ceil(國家數 × 測試比例) 分配測試國家。分組值從缺值列過濾後的有效資料取得，與特徵及目標列保持對齊。
- app.js：模型訓練、測試評估、殘差表和預測器滑桿都沿用同一份切分索引；切分說明會顯示訓練及測試的國家數，例如「依 Country 分組：訓練 117 國／測試 30 國」。

已執行 node --check 檢查 app.js、regression.js 和 config.js，語法檢查通過。

2026-11-01 06:36:34 UTC

使用者

Step 3：作業要求結果要有預測圖，並加上信賴區間或預測區間。請新增：

1. 計算：對目前選定的模型（方法與 k），用訓練集 OLS 的結果，替每一筆測試資料計算
- 95% 信賴區間（平均反應）：$\hat{y} \pm t(0.975, df) \cdot s \cdot \sqrt{x(XX)^{-1}x}$
- 95% 預測區間（單筆新樣本）：$\hat{y} \pm t(0.975, df) \cdot s \cdot \sqrt{1 + x(XX)^{-1}x}$ s 與 df 來自訓練集。regression.js 的 olsSummary 已經有 QR 分解的 R、invUpper、tQuantile，請沿用，不要直接對 XX 求反矩陣。
2. 新增一張「預測圖（測試集）」卡片，用現有的 Chart.js、配色與深淺色主題：
- X 軸：測試樣本依預測值排序
- 預測值畫成線，PI 畫成淺色帶，CI 畫成較深的窄帶
- 實際值畫成點，落在 PI 外的點用不同顏色標示
- 圖例清楚說明 CI 和 PI 的差別
3. 卡片上顯示：PI 實際涵蓋率（實際值落在 PI 內的比例）、平均 PI 寬度、平均 CI 寬度。
4. 即時預測器也要顯示輸入值對應的 95% CI 與 PI。
5. 切換題目、方法、k、seed、測試比例時都要跟著更新。

完成後請用 node 跑一次兩題全特徵模型的 PI 涵蓋率與平均寬度，確認計算正確。

進度

我會先看 olsSummary 如何回傳 QR 的 R、invUpper 與殘差統計，以及目前圖表和即時預測器的更新流程。接著沿用該分解計算 CI/PI，讓題目、方法、k 和切分設定改變時都重新更新。

進度

CI/PI 已接到選定模型和即時預測器，圖表會按測試集預測值排序，並區分 PI 內外的實際值。我現在按使用者要求，用 Node 對兩題各跑一次全特徵 OLS，計算 PI 涵蓋率與平均區間寬度。

Codex

已新增測試集預測圖與 95% CI/PI。區間計算沿用 OLS 的 QR 分解結果：由 R 求 invUpper，以 Rx 計算槓桿值，沒有直接反轉 XX。

主要修改在 regression.js、app.js、index.html 和 style.css：

- 預測圖依預測值排序，顯示預測線、較淺的 PI 帶、較深的 CI 帶，以及實際值；PI 外的實際值使用不同顏色。
- 卡片顯示 PI 涵蓋率、平均 PI 寬度與平均 CI 寬度，圖例說明 CI 是平均反應的不確定範圍，PI 是單筆新樣本的範圍。
- 即時預測器依目前輸入顯示預測值、95% CI 與 95% PI。
- 選擇模型、k、切換題目或調整 seed／測試比例時，圖表和區間會隨目前模型及切分更新。

已用 Node 對兩題各跑一次全特徵模型；語法檢查也通過。

題目	測試集 PI 涵蓋率	平均 PI 寬度	平均 CI 寬度
外送時間預測	95.15%	17.8354 分鐘	1.6085 分鐘
平均壽命預測	94.48%	11.6910 年	1.4312 年

2026-11-01 06:40:21 UTC

使用者

預測圖有兩個可讀性問題：

1. CI 帶很窄，顏色又和 PI 帶接近，圖上幾乎看不到。請讓 CI 用明顯不同的顏色或較高的不透明度，深淺色主題都要清楚。
2. 「實際值（PI 內）」和「實際值（PI 外）」的藍色和紫色太接近，請讓 PI 外的點更醒目（例如換成對比色、稍微放大或加外框）。

進度

我會把 CI 換成藍色系並提高填色不透明度，和珊瑚色 PI 帶拉開；PI 外的實際值改用高對比紅色三角點，加粗外框，並同步更新圖例。淺色與深色主題都會各自設定可辨識的 CI／異常點顏色。

Codex

已調整預測圖的顏色與標記：

- CI 帶改用藍色，增加填色不透明度並加上清楚的邊界線，和珊瑚色 PI 帶區分；淺色及深色主題都有對應配色。
- PI 外的實際值改為較醒目的紅色三角形，尺寸加大並加粗外框；PI 內的點維持藍色圓點。
- 圖例同步更新，PI 外標記也改用紅色描邊樣式。

2026-11-01 06:42:14 UTC

使用者

Step 4：作業要求檢查線性回歸的五大假設。請新增一張「回歸假設檢驗」卡片，針對目前選定的模型，用訓練集殘差（依原始資料列的順序）計算：

1. 線性：殘差 vs 預測值散佈圖（加 y = 0 參考線）

2. 誤差獨立：Durbin-Watson 統計量（約 2 表示無自相關，明顯小於 2 為正自相關）
3. 等變異：Breusch-Pagan 檢定（殘差平方對特徵做回歸）。regression.js 已有 fPValue，可以用 F 版本計算 p 值
4. 常態：殘差的 Q-Q 圖，加上 Jarque-Bera 檢定（自由度 2 的卡方 p 值 = exp(−JB/2)），並顯示偏態與峰度
5. 無多重共線性：沿用現有的 VIF，顯示目前模型中最大的 VIF 與對應特徵

每項都要顯示統計量、p 值或門檻、判定（符合／違反），再用一句白話說明。使用現有的 Chart.js 與主題配色。切換題目、方法、k、seed 時都要更新。

完成後用 node 對兩題的全特徵模型各跑一次，列出 DW、BP、JB、偏態、峰度與最大 VIF。

進度

我會把假設檢驗計算放進 regression.js，讓它使用目前模型的訓練集殘差與現有 OLS 統計量。訓練殘差會依 data.ids 還原到原始 CSV 列序；圖表和五項判定則在選模型時重算。

進度

五項診斷卡與兩張圖已加入；DW 使用從有效列索引映回的原始 CSV 列序，其他診斷依目前選定特徵和訓練集重算。我接著會執行語法檢查，並用 Node 跑兩題全特徵模型，取得要求的 DW、BP、JB、偏態、峰度與最大 VIF。

Codex

已新增「回歸假設檢驗」卡片，會針對目前選定模型的訓練集殘差更新五項結果：

- 線性： 殘差對預測值散佈圖與 y = 0 參考線；另以殘差的二次趨勢 F 檢定輔助判定。
- 誤差獨立： Durbin–Watson，依有效訓練列映回的原始 CSV 列序計算；以 1.5–2.5 作為近似 2 的參考範圍。
- 等變異： Breusch–Pagan F 檢定。
- 常態： 殘差 Q–Q 圖、Jarque–Bera 檢定、偏態與峰度。
- 共線性： 顯示目前模型最大的 VIF 與對應特徵，以 VIF < 5 作為參考門檻。

每項都有統計量或門檻、判定與白話說明。切換題目、方法、k、seed 或測試比例後，診斷會依新模型及訓練集重算。主要修改在 regression.js、app.js、index.html 和 style.css。

已用 Node 對兩題各跑一次全特徵模型，結果如下：

題目	DW	BP F（p 值）	JB（p 值）	偏態	峰度	最大 VIF
外送時間	2.0116	32.3906（5.49×10^{184}）	1,630.5948（數值下溢為 0）	0.7037	5.7071	11,203,807.62（estimated_restaurant_net_margin_usd）
平均壽命	0.7293	3.6654（3.30×10^{7}）	101.6876（8.30×10^{23}）	0.2705	4.1906	199.44（log1p_under-five deaths）

外送模型的 DW 接近 2；平均壽命模型的 DW 顯示依原始列序有正自相關跡象。DW 對列排序敏感，特別是國家 – 年份資料，解讀時需一併考量原始排序方式。兩題的常態與等變異檢定均顯示明顯違反跡象；這些檢定結果會在網頁卡片中隨所選模型更新。

2026-11-01 06:47:06 UTC

使用者

我發現一個方法論問題：目前網頁用測試集 RMSE 挑每個方法的最佳 k，也用測試集 RMSE 挑最佳方法（app.js 的 modeBest 與 runs[m].best）。這等於用測試集調參，違反 crisp-dm-notes.md 寫的「測試集只做最後評估」，報告的測試成績會偏樂觀。

請改成在訓練集內做 5-fold 交叉驗證挑選：

1. 每個方法對每個 k，在每個 fold 的訓練部分重跑特徵選擇與 OLS，在驗證部分算 RMSE，取 5 個 fold 的平均作為 CV RMSE
2. 有 groupColumn 時（平均壽命題）要用分組 fold，同一個國家只能出現在同一個 fold

3. 每個方法的最佳 k 改為 CV RMSE 最小者；最佳方法也用 CV RMSE
   比較。選定後用完整訓練集重新擬合，測試集只用來報告最終成績

4. 「RMSE vs k」圖加一條 CV RMSE 曲線，「最佳 k」標記改依 CV；測試集曲線保留作參考，並標明「僅供參考，不用於選模」

5. fold 分配使用同一個 seed，可重現

完成後用 node 對兩題列出：每個方法 CV 選出的 k、CV RMSE、測試 RMSE、測試 R^2，以及和原本「用測試集選 k」的結果對照。

進度

我會先用目前程式記錄舊版「按測試集 RMSE 選 k」的結果，之後和 CV 選模結果對照。實作時每個 fold 都會重新做特徵選擇與 OLS；外層測試集只保留最終評估用途。

進度

外送題的 5-fold CV 已完成，四種啟用方法都已按 CV 選出 k；舊版測試集挑選結果也已保留作對照。平均壽命題的分組 CV 正在計算中，該題每個國家會完整落在同一 fold。

Codex

已改為只用訓練集的 5-fold CV 選擇方法與 k。每個方法在每個 fold 都會重新做特徵選擇與 OLS，並以五個驗證 fold 的平均 RMSE 評分。平均壽命題的 fold 以國家為單位，同一國家不會跨 fold；fold 分配使用目前 seed，可重現。選定後，模型會用完整訓練集重擬合，測試集只作最終評估。

- RMSE 圖新增虛線 CV RMSE 曲線；測試集曲線標明「僅供參考，不用於選模」，最佳標記依 CV RMSE。
- 方法比較與特徵矩陣表加入 CV RMSE，最佳標記改依 CV。
- 網頁的 CRISP-DM 說明已更新為 CV 選模、測試集最終評估。
- CV 計算會讓出瀏覽器執行時間並顯示狀態，避免長時間無回應。

Node 對兩題執行的結果如下。表中的「CV 選模測試」是 CV 選出的 k 用完整訓練集重擬合後，在測試集的最終分數；右側是舊版按測試 RMSE 選 k 的結果。Exhaustive 在兩題都因特徵數超過 15 而維持停用。

題目	方法	CV 選 k	CV RMSE	CV 選模測試 RMSE	測試 R^2	舊測試選 k	舊測試 RMSE / R^2
外送時間	Forward SFS	5	4.5351	4.7688	0.8793	6	4.7666 / 0.8794
外送時間	RFE	7	4.5364	4.7691	0.8793	10	4.7677 / 0.8793
外送時間	Lasso	5	4.5351	4.7688	0.8793	5	4.7688 / 0.8793
外送時間	ElasticNet	5	4.5351	4.7688	0.8793	5	4.7688 / 0.8793
平均壽命	Forward SFS	3	3.2482	3.0916	0.8468	4	3.0404 / 0.8518
平均壽命	RFE	18	3.2591	3.2053	0.8353	8	2.9893 / 0.8567
平均壽命	Lasso	3	3.2482	3.0916	0.8468	3	3.0916 / 0.8468
平均壽命	ElasticNet	15	3.2415	3.2584	0.8298	4	3.0895 / 0.8470

外送題的最低 CV RMSE 由 Forward、Lasso、ElasticNet 並列；平均壽命題由 ElasticNet 勝出。舊版測試集選模在平均壽命題特別容易挑到測試分數較漂亮的 k，現在這些測試分數只作最終報告。

主要修改在 app.js、regression.js 和 index.html。三個 JavaScript 檔案的 Node 語法檢查通過。

2026-11-01 06:53:06 UTC

使用者

平均壽命題現在由 ElasticNet k = 15 勝出，但它的 CV RMSE（3.2415）和 Forward k = 3（3.2482）只差 0.007，卻多用了 12 個特徵。這個差距在 CV 的誤差範圍內，選複雜模型沒有意義，也不符合成功標準「用較少特徵達成相近表現」。

請改用一個標準誤法則（one-standard-error rule）：

1. 每個方法、每個 k 都計算 5 個 fold RMSE 的標準誤：SE = 標準差 / $\sqrt{5}$

2. 找出所有方法與 k 中 CV RMSE 最小者，門檻 = 最小 CV RMSE + 它的 SE
3. 在 CV RMSE ≤ 門檻的所有（方法, k）中，選 k 最小的；k 相同時選 CV RMSE 較小者
4. 每個方法自己的最佳 k 也用同樣的規則（用該方法自己的最小值與 SE）
5. RMSE vs k 圖的 CV 曲線加上 ±1 SE 的誤差範圍，並畫出門檻線
6. 頁面上說明採用 1-SE 法則

完成後用 node 列出兩題每個方法的最小 CV RMSE、SE、門檻、1-SE 選出的 k、測試 RMSE、測試 R^2 與 MAE，以及最終選定的方法與 k。

進度

我會在每個 k 保留五個 fold 的 RMSE，計算樣本標準差除以 $\sqrt{5}$ 作為 SE；再分別算每個方法的 1-SE 選擇，以及跨所有方法與 k 的全域 1-SE 選擇。圖上會加 SE 誤差棒與對應門檻線。

進度

五折分數和 SE 現在都會保留；每個方法先用自己的最小 CV RMSE 建立方法內門檻，全域則用所有方法與 k 的最低 CV RMSE 建立全域門檻。接下來把兩種 1-SE 選擇結果接到表格、最佳模型提示與 RMSE 圖。

進度

我會先核對 1-SE 選模與圖表更新的實作，再用 Node 重新驗證語法與兩題的輸出摘要，確保最終報告對應目前程式。

進度

我在複核時發現交叉驗證迴圈有一個索引上限變數名稱錯誤（引用了未定義的 sums），會讓折內特徵選擇結果無法正確累積。我先修正，再重新跑實際兩題的 Node 計算。

進度

語法檢查已通過。正在用修正後的折內特徵選擇重跑兩題；這次會直接從每個方法的各 k fold RMSE 計算 1-SE 門檻與測試集指標。

Codex

已實作 1-SE 法則：每個方法和 k 都以 5 個 fold 的 RMSE 平均與標準誤計算門檻；全域選模則在最低 CV RMSE 加一個標準誤的範圍內，選特徵數最少的模型。方法各自的最佳 k 也依同一規則選出。RMSE 圖新增 CV RMSE 的 ±1 SE 誤差範圍和 1-SE 門檻線，頁面也說明了選模方式。

複核時修正了交叉驗證迴圈中的索引變數錯誤，並以 Node 重新計算兩題。下表的測試指標對應各方法自己的 1-SE k；Exhaustive 因特徵數超過現有上限而停用。

外送時間預測

方法	最低 CV RMSE	SE	門檻	1-SE k	測試 RMSE	測試 R^2	測試 MAE
Forward	4.5351	0.0558	4.5908	4	4.7698	0.8792	3.4898
RFE	4.5364	0.0566	4.5930	6	4.7705	0.8792	3.4916
Lasso	4.5351	0.0558	4.5908	4	4.7698	0.8792	3.4898
ElasticNet	4.5351	0.0558	4.5908	4	4.7698	0.8792	3.4898

全域最低 CV RMSE 為 4.5351，門檻為 4.5908；最終選定 Forward，k = 4。

平均壽命預測

方法	最低 CV RMSE	SE	門檻	1-SE k	測試 RMSE	測試 R^2	測試 MAE
Forward	3.2482	0.2033	3.4515	2	3.5870	0.7937	2.8841
RFE	3.2591	0.1054	3.3646	5	3.1128	0.8447	2.4975
Lasso	3.2482	0.2033	3.4515	3	3.0916	0.8468	2.5022
ElasticNet	3.2415	0.0971	3.3386	6	3.2984	0.8256	2.6490

全域最低 CV RMSE 來自 ElasticNet 的 k = 15，門檻為 3.3386；依最少特徵數規則，最終選定 Forward，k = 3。它的 CV RMSE 為 3.2482，只比最低值高約 0.0067；測試 RMSE 為 3.0916、R^2 為 0.8468、MAE 為 2.5022。

修改位於 app.js、index.html 和 style.css。`app.js`、`regression.js` 與 `config.js` 的 Node 語法檢查均通過。

2026-11-01 06:59:46 UTC

使用者

建模與評估都完成了，請在 docs/crisp-dm-notes.md 為兩題補上「4. 建模」「5. 評估」「6. 部署」。所有數字請用目前的程式重新計算（上一輪的 CV 對照表是在修正索引錯誤之前算的，不要沿用）。

1. 建模：五種特徵選擇方法、5-fold CV（壽命題分組 fold）、1-SE 法則的做法與理由；最終選定的方法、k、特徵清單與係數（含 95% CI 與 p 值）
2. 評估：

- 各方法的 CV RMSE、SE、1-SE 選出的 k、測試 RMSE／R^2／MAE
- 「用測試集選 k」vs「CV + 1-SE 選 k」的對照，說明用測試集選模會高估多少
- 逐條對照商業理解的成功標準，標示是否達成
- 預測區間：涵蓋率、平均寬度，以及外送題「短程太寬、長程太窄」的現象
- 五大回歸假設檢驗的結果、對結論的影響，以及可行的改善方式（例如對目標取 log、加權最小平方、穩健標準誤、群集標準誤）

1. 部署：純前端靜態網頁、GitHub Pages、下拉選單兩題與自訂 CSV、即時預測器含區間；使用限制

另外把文件標題改成「HW2 CRISP-DM 工作筆記」，第一題的章節標題加上「第一題：外送時間預測」，和第二題對稱。

進度

我會先讀目前的 CRISP-DM 筆記與程式計算流程，再用現有資料和同一套切分、CV、1-SE 選模重新產生模型係數、區間、評估指標與診斷數字，最後補齊兩題第 4–6 階段。

Codex

已在 crisp-dm-notes.md 補上兩題的「4. 建模」「5. 評估」「6. 部署」，並將文件標題及兩題章節標題改成對稱格式。

所有模型數字都用目前程式重新計算，沒有沿用索引錯誤修正前的 CV 結果。文件包含各方法的 CV RMSE、SE、1-SE 選出的 k 與測試指標、測試集選模對照、成功標準判定、PI 涵蓋率與寬度、五大假設診斷，以及最終模型係數、95% 信賴區間和 p 值。

Exhaustive 因 one-hot 後特徵數超過程式的 15 個上限，兩題都未執行；文件已列明原因，並對其餘四種方法提供重新計算的結果。`git diff --check` 通過。

2026-11-01 07:09:55 UTC

使用者

Step 5 第二部分：README 與網頁說明。

1. 把 README.md 重寫成 HW2 版本：

- 標題 AIoT-HW2-MultipleLR；課程「AIoT 與數據分析（AIoT-DA）」，作業「HW2：Multiple Linear Regression」
- 儲存庫 https://github.com/anjyuelee/AIoT-HW2-MultipleLR，線上網址 https://anjyuelee.github.io/AIoT-HW2-MultipleLR/
- 「作業要求對照表」：逐條列出作業要求（Kaggle 資料集 14–39 個特徵並標示來源、線性回歸、特徵選擇、模型評估、預測圖含信賴區間／預測區間、CRISP-DM 六階段、GPT 輔助內容、NotebookLM 摘要、GitHub 與網頁、加分：下拉選單兩題、加分：任意 CSV 網址），每條寫出在哪裡實現
- 兩題的資料集表格：Kaggle 連結、筆數、候選特徵數、目標、切分方式
- 結果摘要：兩題的最終模型、特徵、CV RMSE、測試指標、PI 涵蓋率、成功標準是否達成
- CRISP-DM 六階段摘要，詳細內容連到 docs/crisp-dm-notes.md
- 主要方法：5-fold CV、1-SE 法則、依國家分組切分、95% CI／PI、五大假設檢驗

- 本機執行方式（python3 -m http.server、兩支前處理腳本）與專案結構
- 「AI 協助說明」章節，內含兩個明確標示的小節：「GPT 輔助內容」（說明哪些部分由 ChatGPT 協助，對話紀錄 PDF 放在 docs/ai-logs/）與「NotebookLM 摘要」（先留 TODO，之後補）
- 截圖已放在 screenshots/：food-overview.png（外送題頂端）、life-overview.png（壽命題頂端）、prediction-interval.png（預測圖）、assumptions.png（回歸假設檢驗）。請在 README 適當位置引用，並刪除舊的 DIC2 截圖檔 compare.png、overview.png、startups.png 與其引用

1. 網頁底部的 CRISP-DM 卡片改成依目前題目顯示：商業目標、成功標準，以及目前模型是否達成每項標準（自訂 CSV 時顯示通用流程）。成功標準的數字寫在 config.js 的 preset 裡：

- 外送時間：測試 RMSE ⩽ 5 分鐘、95% PI 涵蓋率 93–97%、特徵選擇後測試 R^2 比全特徵模型下降 ⩽ 0.01
- 平均壽命：測試 MAE ⩽ 3 年、95% PI 涵蓋率 90–98%、特徵選擇後測試 MAE 比全特徵模型增加 ⩽ 0.5 年

進度

我會先檢查 README、CRISP-DM 卡片的渲染流程、preset
設定與截圖檔名，再更新文件與頁面，並用目前兩題資料確認成功標準會依題目和所選模型正確顯示。

進度

我已確認頁面目前的 CRISP-DM 卡片只有固定流程文字，還沒有依題目顯示商業目標與達標狀態；兩個 preset 的全特徵參考值可以由訓練集直接重算。我正在把卡片改為使用目前選取模型的測試指標與區間涵蓋率即時判定，並同步重寫 README。

Codex

已完成 README 與頁尾說明更新。

- 重寫 README.md：加入作業要求對照、資料集與結果摘要、CRISP-DM、方法、本機執行方式、專案結構、GPT 說明與 NotebookLM TODO，並引用四張指定截圖。
- 在 config.js 為兩題加入商業目標與成功標準；app.js 會依目前題目、模型和測試結果即時顯示各標準是否達成。自訂資料或非預設目標會顯示通用流程。
- 更新 index.html 與 style.css，讓頁尾 CRISP-DM 卡片呈現商業目標、標準和達標狀態，並補上 1-SE 選模說明。
- 移除舊的 compare.png、overview.png、startups.png 及舊版 DIC2 功能連結。

node --check 與 git diff --check 均通過。docs/ai-logs/ 已建立為對話紀錄 PDF 的存放位置，但工作區中目前沒有提供 PDF；README 已說明提交位置。

2026-11-01 07:15:17 UTC

使用者

Step 7：把專案推到 GitHub 的新 repo，並開啟 GitHub Pages。

1. 先確認工作區沒有未提交的變更，有的話先 commit
2. 確認 data/raw/ 沒有被 git 追蹤（git ls-files 裡不能出現 data/raw），原始 CSV 不能推上去
3. 用 GitHub CLI 建立新的公開 repo 並推送： gh repo create anjyuelee/AIoT-HW2-MultipleLR --public --source=. --remote=origin --push 這是新 repo，不要推到原本的 AIoT-DIC2-MultipleLR。分支名稱用 main
4. 開啟 GitHub Pages，來源是 main 分支的根目錄： gh api -X POST repos/anjyuelee/AIoT-HW2-MultipleLR/pages -f "source[branch]=main" -f "source[path]=/"
5. 等部署完成後，確認以下網址都能正常回應（HTTP 200）：

- https://anjyuelee.github.io/AIoT-HW2-MultipleLR/
- https://anjyuelee.github.io/AIoT-HW2-MultipleLR/data/food_delivery_2026.csv
- https://anjyuelee.github.io/AIoT-HW2-MultipleLR/data/life_expectancy.csv

如果 gh 沒有安裝或沒有登入，請停下來告訴我要怎麼處理，不要改用其他方式推送。

進度

我會先核對目前分支、未提交檔案、data/raw/ 追蹤狀態，以及 GitHub CLI 登入情況；確認能建立新 repo 後再依你指定的命令推送到新的 AIoT-HW2-MultipleLR，不會改推舊 repo。

Codex

已停止，尚未建立 repo、推送或開啟 Pages。

目前工作區在 main 分支且沒有未提交變更，因此不需 commit；git ls-files data/raw 也沒有列出任何檔案。gh 已安裝，但 GitHub CLI 的登入 token 無效。

請在終端機重新登入：

```
gh auth login -h github.com
```

完成後告訴我，我再繼續建立並推送到新的 anjyuelee/AIoT-HW2-MultipleLR repo，設定 GitHub Pages 並確認網址回應。

2026-11-01 07:16:39 UTC

使用者

已完成

進度

我會重新確認 GitHub CLI 登入狀態和工作區，再建立新 repo、推送 main，之後設定 Pages 並檢查三個網址。

Codex

gh auth status 仍回報 anjyuelee 的 token 無效，因此我依你的要求停在推送前；尚未建立或修改 repo。

請重新執行 gh auth login -h github.com，確認登入流程完成後，再讓我知道。

2026-11-01 07:17:53 UTC

使用者

確認登入流程完成

進度

我再檢查一次 GitHub CLI 的登入狀態；只有確認有效登入後才會繼續推送。

Codex

目前 gh auth status 仍顯示 token 無效，登入尚未對這個終端機生效。我還沒有建立或推送 repo。

請在此環境的終端機執行 gh auth login -h github.com，完成後再告訴我；我會重新檢查狀態。

2026-11-01 07:25:29 UTC

使用者

請把這個對話的完整紀錄匯出成 docs/ai-logs/codex-hw2-conversation.md，再轉成 PDF：docs/ai-logs/codex-hw2-conversation.pdf

進度

我會先確認工作區可用的對話匯出資源與 PDF 工具，再把本對話內容存成 Markdown 並轉出 PDF。

進度

我找到了本對話的歷史紀錄接口，會按頁讀取可見的使用者與 Codex
訊息，排除內部推理和工具原始輸出，整理成完整對話文字。PDF 會套用 PDF skill 的檢查流程；我先讀它的輸出與驗證規則。

進度

Markdown 與 PDF 已產生。接下來我會檢查頁數與首尾文字，並嘗試渲染 PDF 頁面檢視字型和版面是否正常。

進度

對話頁面共 26 回合，已整理可見的使用者與 Codex 訊息；PDF 共 24
頁，繁體中文字型與首頁版面已確認正常。我會把本次交付回覆也補到紀錄末尾，讓匯出涵蓋到這一輪完成。

Codex

已匯出本對話中可見的 26 回合使用者與 Codex 訊息，包含本輪交付回覆；內部推理與原始工具輸出不在紀錄中。PDF 共 24
頁，已檢查繁體中文字型、頁數與尾端內容。

Markdown 紀錄：

:codex-file-citation{path="/Users/jay/Projects/AIoT-HW2-MultipleLR/docs/ai-logs/codex-hw2-conversation.md" purpose="output"}

PDF 排版版本：

:codex-file-citation{path="/Users/jay/Projects/AIoT-HW2-MultipleLR/docs/ai-logs/codex-hw2-conversation.pdf" purpose="output"}

2026-11-01 14:50:18 UTC

使用者

請依序完成三件事：

【一】把 README「AI 協助說明」裡 NotebookLM 摘要的 TODO 換成正式內容：

1. 「NotebookLM 摘要」小節：

- 使用方式：在 NotebookLM 用 Fast Research 搜尋「Life expectancy WHO dataset multiple linear regression」與「food delivery time prediction linear regression」，匯入 18 個網路來源（另有 2 個匯入失敗），再請它摘要
- 來源清單（標題依 NotebookLM 顯示，部分被截斷）： 外送時間：A Comparative Analysis of Machine Learning Models for Time Prediction in⋯；A Data-Driven Approach for Capacity Planning and Enhancing Courier Effi⋯；Analysis of Influencing Factors of Food Delivery Time - Atlantis Press；arXiv:2503.15177v1 [cs.LG] 19 Mar 2025；Boosting Algorithms for Delivery Time Prediction in Transportation Logistic⋯；Delivery Time Prediction using Linear Regression in ML - Project Gurukul；Determinants of Food-Delivery Timeliness: An Empirical Test Using Multipl⋯；Presentation - Zomato Delivery Time Prediction.pdf - Slideshare；Regression/Food Delivery Time Prediction.ipynb at main · emretuncer256/2⋯ 平均壽命：Linear Regression : Life Expectancy Data from Kaggle - RPubs；Predicting Life Expectancy Using Global Data in 2015 - CAUSEweb；Predicting Life Expectancy with Linear Regression - RPubs；Prediction of WHO Life Expectancy Data Using Multiple Linear Regression⋯；RenatoMaynard/Statistical-Modeling-and-Regression-Analysis-Life-Expect⋯；sachithnimesh/Life-Expectancy-Prediction-using-Multiple-Linear-Regressi⋯；statistical modeling of life expectancy using socioeconomic, mortality, and⋯ 通用：Assumptions of Multiple Linear Regression - Statistics Solutions；Multiple Regression Multicollinearity issue - Cross Validated - Stack Exchange
- 原文引用下方的摘要，標明是 NotebookLM 產生
- 引用截圖 docs/ai-logs/notebooklm.png

1. 新增「與本專案做法的比較」表格：比較缺值處理、特徵選擇、資料切分、共線性處理、兩題的 R^2。重點：

- 摘要中外送題線性迴歸 R^2 約 0.41–0.44，本專案為 0.88，遠高於真實資料的結果，佐證本資料集可能是近似線性生成的合成資料
- 摘要中壽命題 R^2 約 0.74–0.86，本專案在依國家分組切分（測試國家完全未見過）下為 0.85，落在範圍內
- 本專案的不同做法與理由：完整案例而非補值、CV + 1-SE 選模而非 AIC 逐步迴歸、依國家分組切分

- 註明摘要中的數字來自 NotebookLM 整理的來源，未逐一查證

1. docs/crisp-dm-notes.md 兩題的評估段落各加一小段「與網路常見做法比較」
2. 更新作業要求對照表的 NotebookLM 那一列；也在對照表的 GPT 輔助內容那一列連結 docs/ai-logs/codex-hw2-conversation.pdf

NotebookLM 摘要原文： 網路上使用多元線性迴歸處理「平均壽命預測」與「外送時間預測」的做法摘要如下：

- 常用的資料清理方式：處理缺失值時常直接剔除缺失列或採用平均值與內插法進行補值；面對高度偏態資料，會採用對數轉型（Log Transformation）或次方轉型以改善偏態並滿足殘差常態性假設；類別變數則進行獨熱編碼（One-Hot Encoding）或標籤編碼（Label Encoding）。
- 特徵選擇方法：外送預測多利用 Haversine 公式由經緯度算出地理距離，並結合 SelectKBest（互資訊）或樹模型的特徵重要性進行篩選；壽命預測則常用 Pearson 相關係數矩陣、逐步迴歸（Stepwise Selection based on AIC）或 LASSO 迴歸懲罰項篩選顯著變數。
- 評估指標：主要採用 R^2（及 Adjusted R^2）、RMSE、MSE、MAE 與 MAPE 衡量模型擬合優度與預測誤差。
- 遇到的常見問題：包含多元共線性（自變數相關性過高導致 VIF 飆升、迴歸係數不穩定，需刪除重疊特徵）；以及資料存在複雜非線性關係導致殘差違反常態性與同變異性假設，使得線性迴歸在外送時間預測的表現（R^2 約 0.41–0.44）顯著低於集成樹模型。 可供比較的兩大差異：

1. 特徵工程導向：壽命預測著重於社經與健康指標（如受教育年數、GDP、疫苗覆蓋率）的統計顯著性與可解釋性；外送預測則高度依賴地理距離計算與動態實時特徵（如交通、天氣、騎士評分）。
2. 線性模型適用性：壽命預測中多元線性迴歸即可提供較高的解釋力（R^2 常達 0.74–0.86）；外送預測因非線性關係強，線性迴歸僅作為基準模型，實務上多改採 LightGBM 或 XGBoost 等樹模型以大幅提升精準度。

【二】最後重新匯出這個對話，覆蓋 docs/ai-logs/codex-hw2-conversation.md 與 .pdf，要包含【一】這一輪。目前的 PDF 沒有轉換 Markdown：表格顯示成「| 欄位 | 型別 |」，粗體顯示成「文字」。請先把 Markdown 轉成 HTML（表格、粗體、程式碼區塊、清單都要正確呈現）再轉 PDF，轉完檢查幾頁含表格的頁面。

【三】commit 所有變更（含 docs/ai-logs 的三個檔案），不用 push。

進度

我會先核對文件結構與目前 Git 變更，再更新 NotebookLM 內容及兩題的網路做法比較。對話紀錄會重新抓取可見訊息，轉成真正渲染 Markdown 的 HTML 後再輸出 PDF；最後檢查含表格的頁面並 commit 全部變更，不 push。

匯出說明

此紀錄涵蓋截至本輪匯出時可讀取的完整可見對話歷史。

2026-11-01 UTC

Codex

已依本輪要求更新 README 與 CRISP-DM 比較內容，並重新匯出對話紀錄；Markdown 已轉為 HTML 後排版輸出 PDF，含表格、粗體、程式碼區塊及清單。